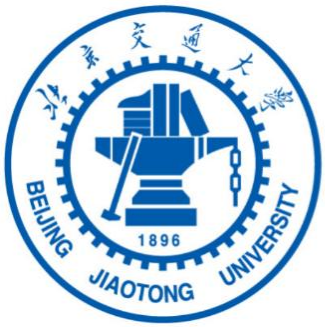


北京交通大學

《人工智能的网络应用》课程综合项目

—— 校园 WiFi 故障调查 Agent 实验报告

姓名：刘俊伟　吴睿娜

学号：23211354　23211361

班级：通信 2302 班

指导教师：陈一帅

摘要

针对楼门外已连接校园 WiFi 却无法访问网页、回到楼内后恢复的问题，本项目设计并实现证据驱动调查 Agent。系统通过网页入口、FastAPI 后端、四个只读工具与网络专业 Skill，对地址配置、分层连通性和室内外快照开展检查，形成支持证据、反证、限制和行动建议。基于 10 个人工模拟案例，对直接 LLM、LLM 加工具和加入 Skill 三组保存输出进行评测。三组标签正确率均为 100%，证据语义通过率为 100%、100%和 95%，综合成功率为 100%、100%和 90%；B、C 组工具调用数分别为 16 次和 10 次。C 组存在正确拒绝因果归因却遗漏原始异常证据的案例，说明减少调用不必然改善调查质量。系统保留原始 Trace、评分依据及版本差异记录，支持复算；结论受小样本、单次运行和工具版本差异限制。

关键词：校园 WiFi；AI Agent；工具调用；网络诊断；证据与反证

一 项目背景与问题定义

我们希望为校园网运维工程师开发一个 WiFi 无法上网调查 Agent，处理楼门外终端已经连接无线网络、网页却无法打开，回到楼内后恢复的事件。目标用户需要快速判断下一项检查，而不是接收一份缺乏依据的常见故障清单。成员提供的经历用于界定问题，本项目以人工构造快照重现症状，不将模拟记录解释为该地点的现场测量。

工程师通常先确认关联状态和地址配置，再检查网关、外部服务、DNS 及校园认证，并结合无线指标和接入点变化进行对照。这些检查跨越多个协议层，单次 ping 失败、信号降低或 BSSID 改变都可能被误当作根因。纯语言问答容易停留在列举原因，Agent 则可以把问题转化为可执行检查，把判断连接到明确的输入、工具返回和反面证据。

代表性事件 W01 中，模拟终端在楼内与门外使用同一设备，相隔 60 秒；门外地址为 10.1.2.20/24、网关 10.1.2.1，认证状态完成。网关和 HTTPS 检查各成功 3 次，DNS 检查失败 3 次。调查任务是比较地址异常、DNS 异常、认证限制及无线因素，解释哪些原因获得支持，同时避免把“门外不能上网”直接等同于覆盖不足。

系统提供网页入口、只读网络工具、专业 Skill、结构化结论与 Trace 保存，支持正常、缺失、矛盾及多因素场景。本次不进行实际校园扫描，不修改设备，不自动修复生产配置，也不承诺仅凭两个快照定位无线干扰源。研究范围是有限观测下的调查方法和可复查证据链，真实部署效果需另行验证。

二 系统架构与 Agent 设计

系统采用浏览器、FastAPI 接口、轻量调查核心、Tool 层、Skill 层和本地 JSON 数据层。用户选择案例并输入问题后，接口校验请求，调查核心建立候选假设并选择检查；工具返

回进入模型上下文，模型形成包含证据、反证、限制与建议的结论。每次网页执行生成独立 Trace 编号与时间，前端展示并支持导出。架构图同时标明交互入口、模型、专业方法和模拟环境，避免把网页展示与调查能力混为一体。

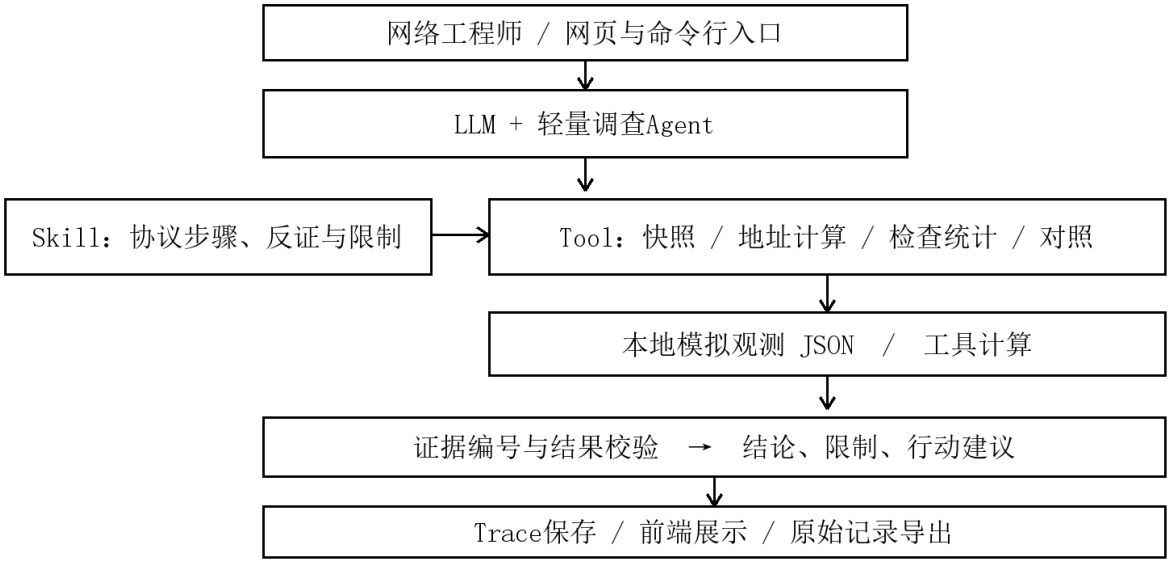


图 1　系统架构及证据流转

模型实验使用 Codex 协作上下文，选择原因是现有环境可以执行真实工具并保存回答，便于观察判断与证据的关系。各组继承默认模型配置，不覆盖型号；接口未提供可锁定的精确服务端版本和采样参数，实验按该条件记录。工程中的自动入口使用 OpenAI 兼容工具协议，并设置模型、端点与密钥环境变量；无配置时保留失败，不用规则演示替代模型实验。

Agent 采用 Python 标准库实现消息循环，工具白名单与结构化参数由程序控制。B 组可调用工具，C 组在调查开始时读取 SKILL.md 并保存 SHA256。模型依据当前问题和已获证据决定下一步，例如地址不可用时优先核对配置，数据冲突时检查口径，不能机械重复全部工具。工具的名称、参数、调用编号和返回值写入 Trace，随后回传给模型继续分析。

核心将单次请求限制为最多 8 轮、20 次工具调用；模型网络请求设置 30 秒上限，并检查总调查预算。两个执行线程避免同步调查阻塞健康检查。未知工具、跨案例访问和错误参数显式拒绝；工具失败与网络故障分别表达。数据缺失保持 null，不以零或 false 补齐。最终输出校验标签、必要字段及证据引用，只能引用允许的观测或成功调用；结构合法仍需专业语义审查。

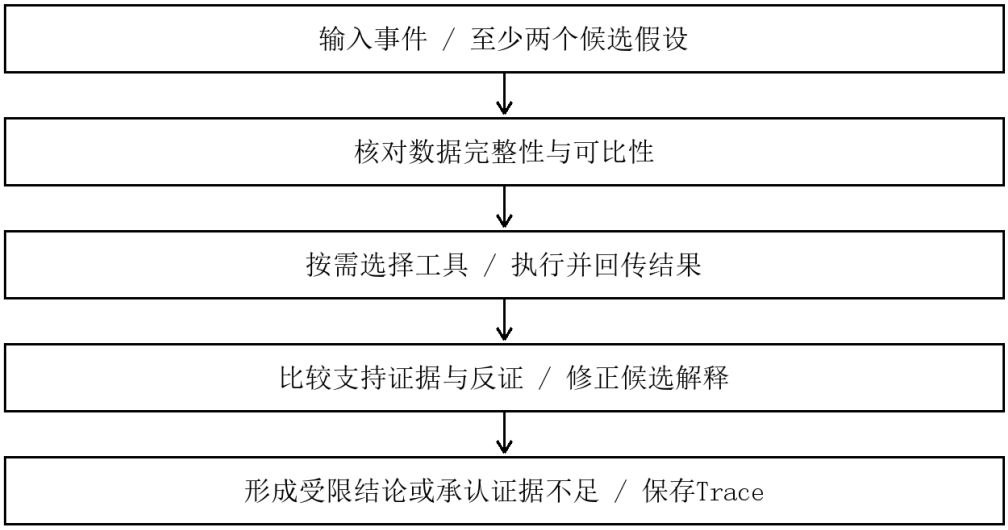


图 2　典型任务执行流程

三 Tool 与 Skill 的设计和实现

表 1　只读工具的输入输出与功能

工具名	输入	主要输出和作用
get_snapshot	case_id、location	读取模拟快照及来源
check_ip_config	case_id、location	地址类别、可用性、网关同网段计算
analyze_connectivity	case_id、location	成功数、有效样本数、比率、冲突与限制
compare_snapshots	case_id	设备、时间差、配置变化和比较限制

本项目实现 get_snapshot、check_ip_config、analyze_connectivity 和 compare_snapshots 四个只读工具。输入以 case_id 为核心，前三项可指定 indoor 或 outdoor；输出统一包含 ok 及 result，失败时返回 error。观测文件与 ground_truth 分离，工具和模型不读取评分答案。前端显示调用原文，便于把一条自然语言判断追溯到数据来源。

check_ip_config 使用 ipaddress 解析 IP 与前缀，识别链路本地等地址类别，计算网关是否处于同一子网。子网检查等价于比较地址与掩码按位与后的网络部分；工具交给标准库处理格式及前缀边界。169.254/16 地址与缺失网关支持检查配置获取，但不能单独证明 DHCP 服务器损坏；某些特殊路由也可能允许子网外网关，所以异常项只作为疑点。

```
iface = ipaddress.ip_interface(ip + "/" + str(prefix))
same_subnet = ipaddress.ip_address(gateway) in iface.network
valid = [v for v in samples if type(v) is bool]
ratio = sum(valid) / len(valid) if valid else None
```

analyze_connectivity 分别统计网关、HTTPS、DNS 和 ICMP。成功率为成功数除以有效布尔样本数，有效率为有效数除以记录总数；没有有效数据时成功率为 null。

compare_snapshots 核对设备和时间，再列出 BSSID、信号及配置变化。300 秒只作为本

实验可比性提示阈值，不能宣称是网络协议规定。上述统计分析已有模拟检查记录，不伪装成实时探测。

Skill 名称为“校园 WiFi 已连接但无法上网调查”，文件位于 skills/wifi-investigation/SKILL.md，按场景、专业知识、步骤、工具选择、验证、常见错误与不确定性组织。它规定先提出替代假设，核对对照条件，按需检查协议层，最后主动找反证。HTTPS 成功只覆盖被测目标，DNS 和 ICMP 结果应分别解释，BSSID 变化不能自动判为漫游失败。

以 W10 为例，B 组在检查快照不可比后继续统计连通性，明确室外 HTTPS 为 0/3；C 组使用 Skill 后优先核对同设备与时间，调用一次对照工具即停止，虽正确拒绝位置归因，却遗漏了原始 HTTPS 失败证据。专业步骤有助于控制结论强度，也可能过早触发停止条件；不能仅凭有 Skill 便认定调查更完整。

结构化结果包含 assessment、label、evidence、counterevidence、limitations 和 recommendations。每条 evidence 由 claim 和 source_ids 组成，程序检查来源编号是否存在、对应调用是否成功，防止引用未执行的工具。专业检查与输出校验共同约束模型，但不把字段齐全视为证据充分；Skill 的效果以第五部分的系统对照评价。

四 Agent 调查过程与工作实例

表 2　B 组 W01 真实调查记录

步骤	操作	实际信息与判断
1	读取同一原始观测	提出 DNS、整体中断、缓存等替代假设
2	analyze_connectivity(W01)	B-W01-1；DNS 为 0/3，网关与 HTTPS 为 3/3
3	支持与反证分析	支持 DNS 层候选；HTTPS 可达削弱完全断网解释
4	输出受限结论	核对查询目标、响应码与解析器，不确定服务器根因

选取 B 组 W01 的真实模型调查记录。用户事件为“室外网页打不开，回楼内恢复，请调查”。模型首先保留室外 DNS 解析路径异常、无线或上游整体中断，以及 HTTPS 缓存或预解析掩盖 DNS 故障等候选解释。这样的假设集合既覆盖常见故障，也给看似不一致的测试组合保留了机制上的可能性。

模型选择 analyze_connectivity，输入为{"case_id":"W01"}，调用编号 B-W01-1。工具实际返回 ok=true；gateway、https、icmp 的 successes 和 valid 均为 3，success_ratio 为 1.0；dns 的 successes 为 0、valid 为 3、success_ratio 为 0.0；auth 为 complete，conflicts 为空。返回同时提示已有记录与单目标检查的边界。完整输入输出保存在 B_calls.json，不依赖截图中的文字来推测执行结果。

模型引用“室外 DNS 0/3，网关、HTTPS 与 ICMP 均 3/3，认证完成”支持 DNS 层候选，并给出“室外 DNS 检查连续失败而其他路径成功，优先怀疑 DNS；不能直接归因于位置或指定服务器”的判断。HTTPS 成功削弱完全断网的解释，认证完成也削弱尚未完成门户授权的假设；这些是对替代解释的限制，不等于已经排除所有无线或上游问题。

DNS 失败与 HTTPS 成功并非必然矛盾。缓存、预解析地址、不同目标或不同解析器都可能形成这一组合；原始快照没有完整标明目标与解析方式，因此不能把 DNS 层现象继续推成服务器损坏。模型建议核对查询目标、响应码与解析器，比较室内外同一查询，并对齐时间。新增测量后仍需更新判断，不能把第一项异常固定成唯一根因。

网页端另通过真实 HTTP 完成问题提交、确定性工具执行、结果展示与 Trace 导出，保存了界面截图及联调记录。该界面验证的是可运行闭环；第四部分的模型判断依据来自上述 Codex 记录。两类记录分别说明程序可执行和模型如何使用证据，避免将预存样例回放混作当次模型调用。

五 实验设计评测结果与分析

表 3　十类测试案例及预设可接受判断

案例	关键输入与判断条件	可接受类别
W01	DNS 0/3，HTTPS 与网关 3/3	dns
W02	169.254 链路本地地址、网关缺失	ip_config
W03	认证 required，HTTPS 失败，其余可达	authentication
W04	RSSI -86，网关与 HTTPS 间歇失败	wireless_uncertain
W05	关键配置与检查缺失	insufficient
W06	网关失败/认证 required 与 HTTPS 成功并存	conflicting
W07	BSSID 改变但各项检查正常	normal
W08	ICMP 失败，HTTPS 与 DNS 正常	normal
W09	DNS 与认证多层异常并存	mixed
W10	不同设备、间隔 10800 秒，室外 HTTPS 失败	insufficient

测试集由 10 个预先构造的案例组成，分别涉及 DNS 检查失败、链路本地地址、认证未完成、无线间歇异常、关键数据缺失、观测不一致、正常接入点变化、仅 ICMP 失败、多层异常及不可比快照。答案按可接受调查层次定义，例如 mixed 表示多项异常并存而非已证明独立根因，insufficient 允许合理拒绝归因。模拟条件可控，不能代表校园故障的自然分布。

A 组直接分析同一原始观测，B 组开放工具，C 组加入专业 Skill。各受试上下文不继承主对话历史，禁止读取标准答案和其他组回答，最终保留逐案 JSON。三组尽可能保持基础

配置和数据范围一致；工具权限与 Skill 是主要比较因素。单次实验不挑选最好答案，也不把规则演示或 mock 接口测试计入模型样本。

结论正确率按标签是否进入预设可接受集合计算。证据合格率依据每案两条语义判据，通过条数除以总判据数；独立审阅须引用回答原句并写明理由，原始回答用 SHA256 绑定。严重误断言包括捏造现场根因、把缺失当失败或仅凭 ICMP/BSSID 确定断网与漫游故障。任务成功要求标签合格、两条语义均通过且无严重误断言。另统计真实领域工具调用数，不估填不可得的 token 与模型耗时。

三组标签均为 10/10，A/B 证据语义判据均通过 20/20，C 通过 19/20；严重误断言均为 0/10。综合成功率分别为 100%、100%和 90%。B 实际调用 16 次，C 调用 10 次，减少 37.5%，但少调用伴随一项证据遗漏，不能单凭成本更低认定更优。图表按本轮保存的逐案回答与独立审阅生成，未报告模型耗时或 token 估计。

表 4　三组实测对照 每组 10 例单次运行

指标	**A 直接 LLM**	**B 工具**	**C 工具和 Skill**
标签正确率	100%（10/10）	100%（10/10）	100%（10/10）
证据语义通过率	100%（20/20）	100%（20/20）	95%（19/20）
严重误断言率	0%（0/10）	0%（0/10）	0%（0/10）
综合成功率	100%（10/10）	100%（10/10）	90%（9/10）
实际领域工具调用	0	16	10
模型版本/采样锁定	平台默认，未锁定	平台默认，未锁定	平台默认，未锁定

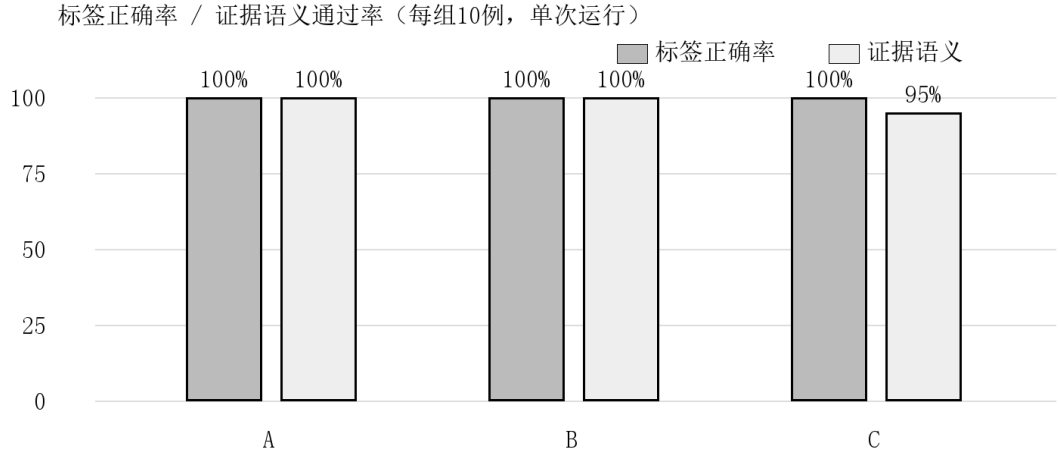


图 3　标签与证据语义对照 单次实验，无误差线

C 组 W10 是模型调查中的不理想案例。模型指出“不能将记录差异归因于位置”，并引用设备不同、相隔 10800 秒等证据；但以“本次工具没有返回各层测试统计”为由停止，未明确保留原始室外 HTTPS 0/3 这一异常。其标签正确、没有严重误断言，第二条语义判据

仍不通过。改进应是在承认因果不足的同时保留已知异常，并补查缺少的检查层，而不是把可比性不足当成停止读取所有证据的理由。

A/B 记录形成于 11 月 4 日，C 组在 11 月 6 日补充运行。期间工具将缺失样本提示从 conflicts 移到 warnings，修复了缺失与冲突混淆；历史工具返回保留原样，重算不完全一致的条目应解释版本差异。服务端精确模型版本不可锁定，三组也不是同时运行，因而结果适用于探索性比较，不能把差异完全归因于 Skill。

旧 B 组 16 条工具返回中 6 条与当前版本逐字一致，其余 10 条涉及新增 warnings 字段或缺失提示迁移；按记录在 version-compatibility.json 中的显式规范化规则，16 条均兼容。C 组 10 条与当前工具精确一致。此核验保留版本差异，不改写历史日志，也不将重算差异当成模型计算错误。

一个明确的不理想案例是规则演示早期在 W02、W04 把缺失提示当成冲突。W02 包含 169.254 地址与缺失网关，W04 的 DNS 样本缺失，提示本意是不能将 null 计为失败，程序却优先匹配 conflicts，遮蔽了更合适的判断。修复把数据质量提示独立为 warnings，并新增回归验证，分别得到 ip_config 和 wireless_uncertain。这是工程分支错误，不当作某组 LLM 失败。

实验还需检验 Skill 的额外成本：重复读取已给定数据可能增加调用，却未增加有效证据。若三组标签相同，应分析小样本的天花板效应，并用语义限制和反证指标观察差别。后续可增加未参与规则设计的盲测、工具错误与更多重复运行；当前人工案例、少量检查及组内关联都限制了泛化和显著性结论。

六 可运行系统与软件实现

系统采用原生 HTML、CSS 和 JavaScript 前端，FastAPI 与 Uvicorn 后端，Python 3.12 验证运行。网页提供横向案例选择、问题入口、观测查看、证据与反证、历史记录及 JSON 导出；POST /investigate 触发后端调查，生成 trace_id 与 UTC 时间并保存到 results/web_traces。启动 MVP.cmd 用于避开 PowerShell 脚本执行策略限制，服务仅监听 127.0.0.1:8765。

代码主要包括 backend/app.py 接口、src/engine.py 调查核心、src/tools.py 工具、Skill 文件、data 模拟观测和 tests 测试。模型适配使用 NETAI_BASE_URL、NETAI_MODEL 及 NETAI_API_KEY 环境变量，缺配置时明确 failed，不自动回退规则；密钥不进入网页输入或提交包。已有 Codex 回答作为预存实验查看，界面不会把读取记录显示成新模型调用。

阶段一已保存 21 项自动测试通过的记录，覆盖工具、参数、证据来源、Trace 往返、错误码及健康检查；浏览器经 HTTP 实际执行 10 个模拟案例，验证 W02/W04 修复、导出及记

录查看。源码、HLD、前端设计文档、截图和联调摘要均已归档。复现先安装 requirements.txt，再运行启动入口；本地在线模型入口与 Codex 协作实验是不同运行途径，报告分别说明其条件。



图 4　真实 MVP 界面的输入与调查记录读取 局部



图 5　真实工具输入与返回 局部，预存 Codex 调查记录

七 总结与学习反思

项目把“已经连接 WiFi 却无法上网”转化为可检查的协议层问题。Agent 负责组织假设与调查，Tool 执行地址计算、有效样本统计和对照，Skill 规范反证与不确定性。子网划分、DNS 与认证知识帮助解释现象，尤其说明关联成功不等于业务可用。

LLM 适合理解描述、选择下一项检查、比较解释和组织建议；地址运算、原始读数、样本分母及来源校验应交给确定性程序。AI 在接口清楚、证据完整时容易形成可读说明，在缺失、矛盾或混杂条件下仍需约束。开发中必须检查 null 处理、分支优先级、协议适用条件和评测分母。

下一步优先完善可比测量与盲测，减少重复调用，再评估真实模型服务与现场数据。AI 辅助生成了方案、代码和文字，成员应分别理解并复现主要模块，结合真实审阅确认结论，而不能用一次成功演示替代可靠性证据。

参考资料与成员分工

[1] RFC 2131. Dynamic Host Configuration Protocol. https://www.rfc-editor.org/rfc/rfc2131 。

[2] RFC 3927. Dynamic Configuration of IPv4 Link-Local Addresses. https://www.rfc-editor.org/rfc/rfc3927 。

[3] RFC 1034. Domain Names - Concepts and Facilities. https://www.rfc-editor.org/rfc/rfc1034 。

[4] 《人工智能的网络应用》课程综合项目要求；项目源码、protocol.json 和 results/report-evaluation 原始记录。

成员责任分配：刘俊伟（23211354）占 50%，负责问题定义、架构、Agent 与 Tool、后端接口和运行联调说明；吴睿娜（23211361）占 50%，负责 Skill、案例及评测、前端交互、设计文档与报告整理。两人共同复核证据、结论与提交材料，并应互相讲解完整工作流。此为责任安排，个人独立操作完成情况未另行留存证明。

AI 辅助说明：成员在对话中提出楼门外 WiFi 场景，确定不做现场采集、使用模拟数据，并选择 NS 主机式界面与报告模板。Codex 辅助生成方案、代码、图表和报告，执行测试与评测整理。代表性修改包括：针对脚本启动受阻增加 CMD 入口；将无效探测与有效失败区分；保留 C-W10 遗漏证据及 B 组工具版本差异，未修改原始输出以提高分数。对应代码、测试与原始日志可核查，详见 docs/AI 辅助与小组分工.md。